



SolR, l'ancêtre d'Elastic



Formateur : Franck MARIN, société Radioactiv'IT





Lucene, CNet et Fondation...











A l'origine Lucene



Solr (comme Elastic Search) est à l'origine basé sur Lucene.

1999, Doug Cutting développe le moteur d'indexation Lucene et le met à disposition sus SourceForge en mars 2000

En 2001, Lucene rejoint le groupe de projet Jakarta de la Fondation Apache

EN 2005, il devient top projet indépendant de la fondation





Puis CNet et Solr

2004, CNet créé la surcouche à Lucene SolR pour ses propres besoins

2006, CNet libère le projet et l'offre à la Fondation Apache (il rentre en incubation)

2007, SolR est validé par la fondation et son écosystème croit vite

2009, le créateur de SolR chez Cnet co créé LucidWorks pour assurer le support commercial de la solution. La communauté continue de croître et les premières recherches clusterisées sont rendu possible par Carrot2





Et finalement SolR = Lucene

2010, Fusion des projets et des équipes de développement Lucene et SolR

Octobre 2012, Solr 4 inclut des fonctions cloud SolrCloud

2015, Solr 5 deploiement stand alone uniquement (plus de war, le jar du web)

2017, Solr 7 et sa dernière version sorti le 21 décembre 7.2. Nouvelles fonctionnalités mathématiques, auto-scaling...





Les moteurs d'indexations

Solr est un moteur d'indexation, il va permettre de gagner du temps sur les recherches full text.

Il va pouvoir intégrer dans son index du texte et des documents (PDF, DocX...) mais aussi des nombres, des dates, des coordonnées géographiques, et autres.

A quoi sert l'index?

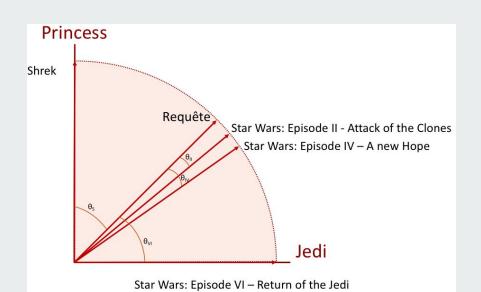




Pour quels besoins?

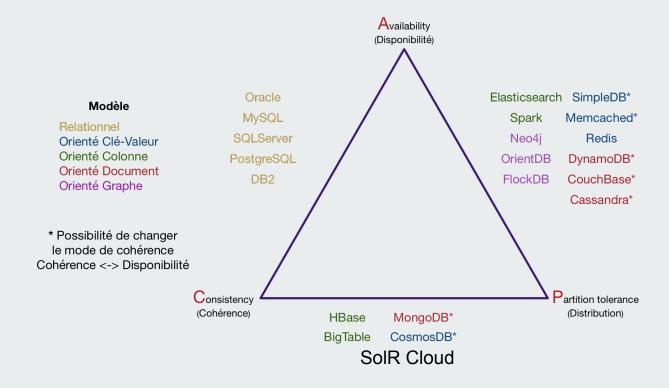
La théorie des moteurs de recherche

- On va chercher dans une base de film les mots Princess et Jedi.
- La requête est un vecteur
- Chaque document est un vecteur
- La pertinence est le cos de l'angle entre le vecteur de la requête et le vecteur du document.













Fonctionnalités de la solution

- Prise en compte des racines linguistiques :
 Développer, Développeront et Developpement seront indéxés en un unique "developp"
- Requêtes structurés et proximité des mots
- Recherche progressive, dites recherche par facette

Exemple facette : http://www.gripic.fr/productions-scientifiques





Fonctionnalités de la solution

• Possibilité de d'identifier le contenu similaire

Exemple contenu similaire: http://www.educauto.org/ressources-mediatheque/circuit-electrique-1





Fonctionnalités de la solution

- Classement par occurrences et positions dans le document
- Gestion des mots insignifiants
- Suggestion de recherche et autocomplétion

Exemple autocompletion : http://www.alimenterre.org/recherche





Fonctionnalités de la solution

- Mise en cache des résultats
- Prise en compte des synonymes
- Proximité géographique





Quels sont les équivalents?











Quand l'utiliser et quand préférer autre chose?

Depuis sa sortie, ElasticSearch a été un tsunami sur le tranquille monde de Solr. Société dynamique, fonctionnalités innovantes, levé de fond de 100 millions de dollars. La Fondation Apache ne peut pas suivre.

La stack ELK est aussi un point en faveur d'Elastic Search.





Intérêt de la solution / Quand l'utiliser et quand préférer autre chose ?

Qu'est-ce qui joue pour lui alors?

- Plus en phase avec la philosophie Open Source
- Des technologies qui peuvent rassurer certains développeurs / administrateur système
 - ZooKeeper
 - Java
 - 0 ...
- Des plugins parfois conçu spécifiquement pour Solr





Qui l'utilise?

Aol.



























@Rakuten Buy.com



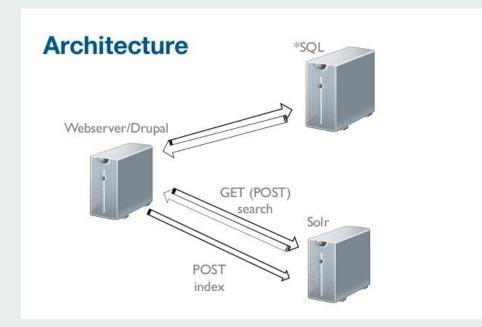




Analyse d'un cas client











Point sur les offres cloud

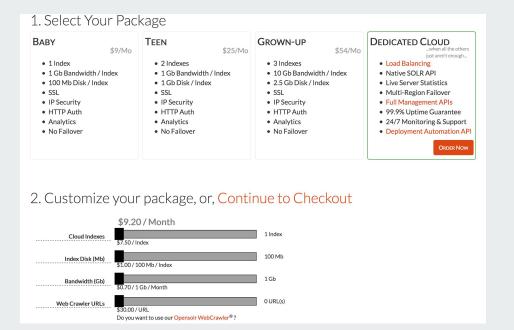
Assez peu d'offres sur le marché, écraser par les offres Elastic





Point sur les offres cloud



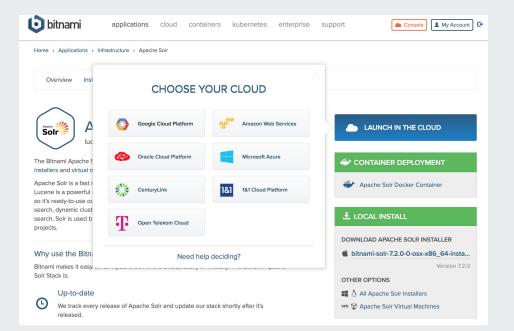






Point sur les offres cloud

Bitnami, hébergement via image pré-construite







Bon appétit